<테이블 생성 및 데이터 로드>

1. 각 테이블의 TRUE/FALSE 값으로 나오는 컬럼의 형식을 무엇으로 할 것인가?
tinyint(1) or text

2. 비어있는 값을 모두 NULL로 할 것인가? 다른 값으로 채워야 하는 경우가 존재하는가? (지금은 모두 NULL로 설정해놓은 상태)

<테이블 확인>

1. 중복 행

각 @테이블의 @_id 컬럼에 대해 중복 처리 필요. 어떤 방식으로 처리할 것인가?

users의 user_id, movies의 movie_id, watch_history의 session_id,
recommendation_logs의 recommendation_id, search_logs의 search_id, reviews의 review_id

2. 결측값

각 테이블에서 NULL값이 50% 이상 존재하는 컬럼들에 대해 결측값 처리가 필요한가? 필요하면 어떤 방식으로 처리할 것인가? (NULL이 의미상으로는 정상으로 보임.)

-- movies: genre_secondary, production_budget_missing, box_office_revenue, number_of_seasons,
number_of_episodes

-- watch_history: user_rating

-- search_logs: clicked_result_position

3. 이상치 및 기타

3.1 users 테이블

-- age: 사용자 나이

최소값 -7, 최대값 109로 불가능한 숫자 포함. age < 0인 행이 19개 있음.

-- subscription_start_date: 구독 시작일

created_at 보다 빠른 경우가 있는데 이게 어떻게 가능한가? 구독을 하려면 계정을 먼저 생성해야 하는 것 아닌가?

-- is_active: 현재 활성 여부

구독 여부와는 다른 것인가? ex. 구독을 지속하고 있지만 일정 기간 이상 사용을 안 하면 비활성 (-> 그렇다면 이탈했다고 볼 수는 없고 이탈 위험이라고 보면 되는가?)

-- monthly_spend: 월 평균 지출 금액

최소값 0.11, 최대값 997.8인데 평균값은 약 22.14 -> 지나치게 큰 값이 소수 존재.

3.2 movies 테이블

-- duration_minutes = 0 인 행이 하나 존재.

-- duration_minutes를 1시간 단위로 잘라본 것 -> 대부분 0~3시간.

-- 0~1시간 350

-- 1~2시간 517

-- 2~3시간 146

-- 3~4시간 2

-- 5~6시간 4

-- 6~7시간 6

-- 7~8시간 4

-- 8~9시간 7

-- 9시간 이상 4

3.3 watch_history 테이블

watch_duration_minutes 최소값 0.2, 최대값 799.3인데 평균값 약 65.6 -> 지나치게 큰 값이 소수 존재

4. 기간

users의 subscription_start_date 기간은 2022-08-02 ~ 2025-08-01

users의 created_at 기간은 2022-08-03 08:42:45 ~ 2025-08-02 14:44:19

movies의 added_to_platform 기간은 2020-08-02 ~ 2025-08-01

나머지 테이블의 date 컬럼의 기간은 2024-01-01 ~ 2025-12-31 로 동일

5. device type

users의 primary_device는
Tablet, Laptop, Smart TV, Mobile, Desktop, Gaming Console

watch_history의 device_type은
Tablet, Laptop, Smart TV, Mobile, Desktop

recommendation_logs, search_logs, reviews의 device_type은
Tablet, Laptop, Smart TV, Mobile

6. 다른 테이블에서의 user_id와 movie_id의 사용

watch_history

사용자가 총 10000명이고 watch_history 테이블에도 사용자가 10000명이 있으니
-> 모든 사용자는 1회 이상 시청을 했고, 총 105000건의 시청 기록에 나눠져 있음.

영화가 총 1000편이고 watch_history 테이블에도 영화가 1000편이 있으니
-> 모든 영화는 1회 이상 시청되었고, 총 105000건의 시청 기록에 나눠져 있음.

recommendation_logs

사용자는 총 10000명이고 recommendation_logs 테이블에는 사용자가 9921명 있음.

영화가 총 1000편이고 recommendation_logs 테이블에도 영화가 1000편이 있으니
-> 모든 영화는 1회 이상 추천됨.

search_logs

사용자는 총 10000명이고 search_logs 테이블에는 사용자가 9186명 있음.

reviews

사용자는 총 10000명이고 reviews 테이블에는 사용자가 7761명 있음.

영화가 총 1000편이고 reviews 테이블에도 영화가 1000편이 있으니
-> 모든 영화에 대해 1회 이상 후기가 작성됨.