모델링 분석 흐름 총 정리

1. 데이터 준비 및 타겟 변수 설정

Dormant User를 휴면 유저(1)로 정의하고 나머지를 정상(0)으로 설정

행동 변수(시청, 검색, 리뷰 등)와 사용자 속성(나이, 성별, 구독 플랜 등) 총 15개 변수를 선 택

범주형 변수는 One-Hot Encoding으로 처리

로지스틱 회귀를 위해 StandardScaler로 스케일링도 적용

2. 모델 학습 및 성능 비교 (6개 모델)

[Logistic Regression, Decision Tree, Random Forest, GBM, XGBoost, LightGBM] → 총 6개 모델 비교

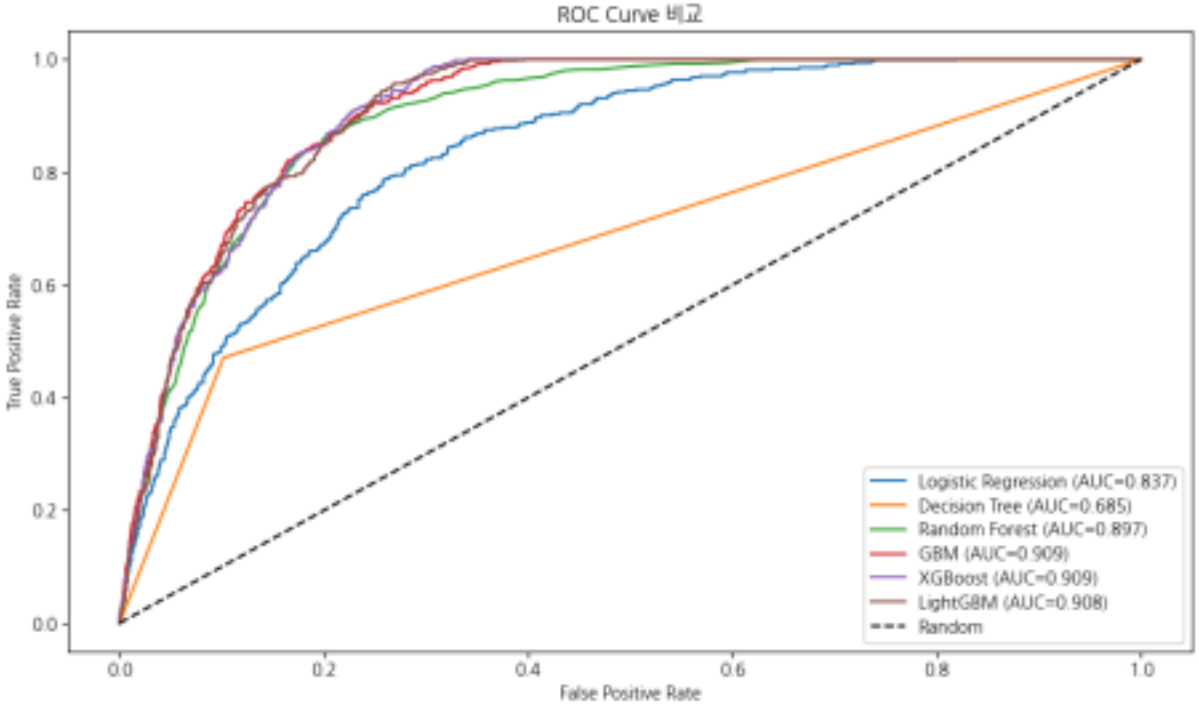
AUC 기준으로 GBM(0.909) ≈ XGBoost(0.909) ≈ LightGBM(0.908)이 상위권
Decision Tree(0.685)가 가장 낮음
Recall 측면에서는 XGBoost(0.846)와 LightGBM(0.800)이 우수
Precision은 GBM(0.661)과 Random Forest(0.668)이 높았음

결과
→ GBM(0.909) ≈ XGBoost(0.909) ≈ LightGBM(0.908) // 선택 예정

모델 성능 선택 기준 : Recall > AUC > F1 > Precision

참고이미지

모델링 분석 흐름 총 정리 1



3. 과적합 판정

Train AUC vs Test AUC Gap을 비교한 결과
Random Forest(Gap 0.1031)와 Decision Tree(Gap 0.3155)는 심각한 과적합 상태
XGBoost(0.0638)와 LightGBM(0.0840)도 과적합 의심 수준

결과
→ 그나마 Gap이 적은 XGBoost(0.0638) // 선택 예정
→ 추후 XGBoost은 하이퍼파라미터 튜닝 진행 예정

4. 최종모델 선택 및 Feature Importance 기반 변수 선택

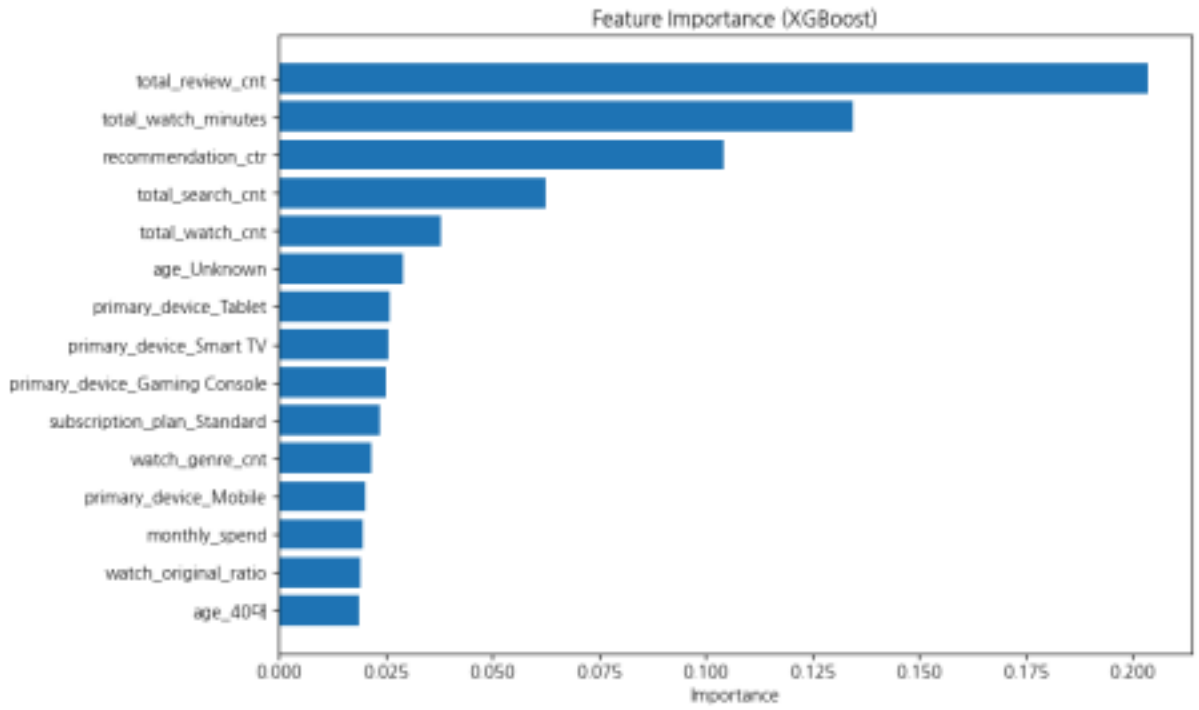
최종 모델 : XGBoost

Feature Importance 분석 결과 상위 5개 변수를 선택
→ total_review_cnt(0.202)
total_watch_minutes(0.134)
recommendation_ctr(0.105)
total_search_cnt(0.063)
total_watch_cnt(0.040)
순으로 확인됨.

결과

→ 행동 기반 변수가 휴면 예측에 핵심적임을 확인하였음.

참고이미지



5. 하이퍼파라미터 튜닝 (XGBoost)

→ Feature Importance를 통해 5개의 상위 변수만 선택하여 기존 XGBoost 모델에 재학 습 진행

상위 5개 변수만으로 RandomizedSearchCV(50회 탐색, 5-Fold CV)를 수행

최적 파라미터는 아래와 같이 결정

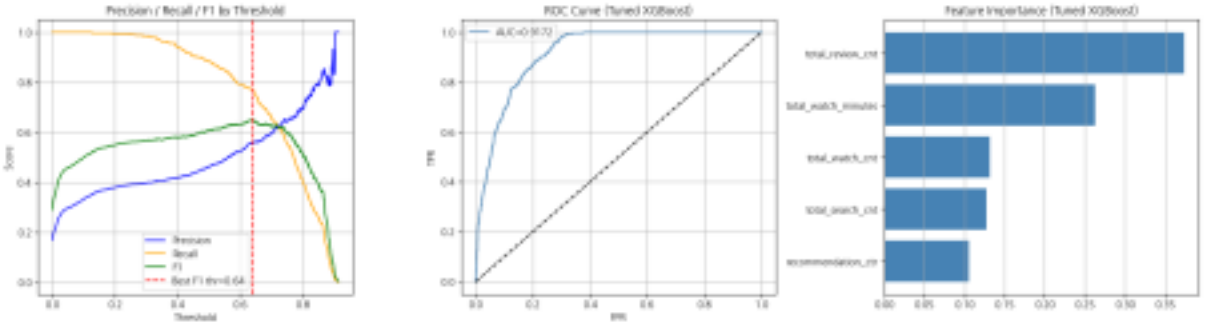
learning_rate 0.03, gamma 0.5,
reg_alpha 0.1, colsample_bytree 0.7,
subsample 0.8, max_depth 5

결과

→ CV Best AUC는 0.9064
→ 튜닝 후 과적합 판정에서 XGBoost(tuned)는 ✅ 안정적으로 개선되었음.

참고이미지

모델링 분석 흐름 총 정리 3



6. 임계값(Threshold) 조정

휴면 예측 특성상 미탐지(FN)가 더 위험하므로 Recall 우선 방향으로 임계값을 조정하였음. Recall ≥ 0.75를 만족하는 최적 임계값을 적용

기본값 0.5 대비 Recall을 높이고 FN을 줄이는 방향으로 최적화하였음.

결과

→ 최적 임계값 : 0.64

7. 혼동 행렬 분석

전체 실제 휴면 유저는 342명(FN 78 + TP 264)

지표	수치	의미
TP : 264명	77.2%	휴면 유저 중 정확히 잡아낸 수
FN : 78명	22.8%	휴면 유저인데 놓친 수
Recall	0.7719	휴면 유저 10명 중 약 8명 탐지

→ 실무적 판단

관점	판단
비용 관점	FN 78명 × 1인당 휴면 손실 비용 계산 필요
변수 추가 검토	avg_watch_pct, watch_genre_cnt 등 재포함 고려

해석 및 결과

→ 긍정적인 부분 : 휴면 유저 342명 중 264명을 사전에 탐지

// 이 264명에게 선제적으로 쿠폰, 콘텐츠 추천, 알림 등 리텐션 액션을 취할 수 있음 → 아쉬운 부분 : Recall 목표(0.75)는 달성했으나, 여전히 78명의 휴면 유저를 미탐지하여 추가 개선 여지 존재

// 78명은 여전히 미탐지 상태로 아무런 개입 없이 휴면 가능성이 높음

→ 현재 모델로 휴면 유저의 77.2%를 선제 탐지할 수 있어 실무 활용은 충분히 가능한 수준

8. KS 분석

튜닝된 XGBoost 모델로 휴면 유저와 정상 유저의 예측 확률 분포를 비교함.

KS 통계량이 높을수록 두 집단을 잘 분리한다는 의미로, 모델의 판별력을 시각적으로 확인 함.

결과

→ KS 통계량 : 0.6835 , KS p-value: 0.0000 // 0.4 이상이므로 정상 분리 확인

9. IV 분석 (Information Value)

수치형 변수들의 예측력을 IV로 측정하였음.

IV < 0.1 → 약한 예측력

IV ≤ 0.3 → 강한 예측력

→ Feature Importance 결과와 교차 검증하는 용도로 활용함.

결과

→ 변수 중요도와 IV 의 상위 변수 TOP3 : total_watch_minutes , total_review_cnt ,total_search_cnt

→ Dormant User : [total_watch_minutes , total_review_cnt ,total_search_cnt] 의 영향력 우세

10. PSI 분석 (Population Stability Index)

튜닝된 모델의 Train 예측 확률 분포와 Test 예측 확률 분포를 비교하였음.
PSI < 0.1 → 안정적
PSI = 0.1~0.2 → 주의
PSI ≤ 0.2 → 모델 재학습

결과

→ 실제 PSI 점수: 0.0084 // 안정적

11. 분석 인사이트 핵심 정리

11-1. 휴면 유저의 핵심 특징은 "행동 감소"

Feature Importance와 IV 분석 모두에서 시청 관련 변수가 압도적 1위

변수	의미
total_review_cnt	리뷰 안 씀 → 콘텐츠에 흥미 잃음
total_watch_minutes	시청 시간 감소 → 이탈 직전 신호
total_watch_cnt	시청 횟수 감소 → 접속 자체가 감소
recommendation_ctr	추천을 클릭 안 함 → 추천 알고리즘이 안 맞음
total_search_cnt	검색을 안 함 → 볼 콘텐츠를 못 찾고 있음

결론 : 휴면 유저는 갑자기 떠나는 게 아니라 서서히 행동이 줄어드는 패턴을 보임

11-2. 휴면 예측은 충분히 가능한 수준

튜닝된 XGBoost 기준으로 AUC 0.906, Recall 0.75 이상을 달성

11-3. 추천 알고리즘 개선이 시급

recommendation_ctr이 Feature Importance 3위임에도 IV는 0.03으로 낮음.
→ 이는 추천을 클릭하는 유저와 안 하는 유저 간 휴면 차이가 크지 않다는 의미
→ 현재 추천 알고리즘이 이탈 방지에 효과적으로 작동하지 않고 있을 가능성이 높음

11-4. 검색 행동이 숨겨진 신호

total_search_cnt는 IV 0.14로 정상 범위에서 유의미한 예측력
→ 검색을 많이 할수록 볼 콘텐츠를 찾지 못하고 있다는 신호
→ 검색했지만 시청으로 이어지지 않은 유저를 집중 타겟으로 삼을 필요가 있어보임

11-5. 구독 플랜과 월 지출은 휴면과 무관

monthly_spend IV가 0.008로 거의 예측력 X

→ 돈을 많이 내는 유저도 휴면한다는 의미
→ 가격 정책보다 콘텐츠 경험이 이탈의 핵심 원인으로 보여짐

11-6. 실무 적용 방향 (휴면 방지 전략)

대상	전략
시청 횟수/시간 급감 유저	즉시 알림 또는 개인화 콘텐츠 푸시
추천 클릭률 낮은 유저	추천 알고리즘 개인화 강화
검색은 하지만 시청 안하는 유저	검색 결과 품질 개선 및 큐레이션 제공
리뷰 작성이 갑자기 줄어든 유저	콘텐츠 만족도 설문 또는 혜택 제공

핵심 : "휴면은 예고 없이 오는 게 아니라 행동 데이터에 이미 신호가 있다"

11-7. 혼동 행렬 분석

전체 실제 휴면 유저는 342명(FN 78 + TP 264)

지표	수치	의미
TP : 264명	77.2%	휴면 유저 중 정확히 잡아낸 수
FN : 78명	22.8%	휴면 유저인데 놓친 수
Recall	0.7719	휴면 유저 10명 중 약 8명 탐지

→ 실무적 판단

관점	판단
비용 관점	FN 78명 × 1인당 휴면 손실 비용 계산 필요
변수 추가 검토	avg_watch_pct, watch_genre_cnt 등 재포함 고려

전체 흐름 총정리

타겟 변수 설정
Dormant User → 1, 나머지 → 0
↓
변수 선택 및 전처리
15개 변수 선택 → One-Hot Encoding → StandardScaler
↓
Train/Test 분할
Train 70% / Test 30% (stratify 적용)
↓
6개 모델 학습
Logistic Regression / Decision Tree / Random Forest
GBM / XGBoost / LightGBM
↓
성능 비교 (result_df)
Accuracy / Precision / Recall / F1 / AUC
↓
교차검증 (StratifiedKFold 5-Fold)
CV AUC 비교 → 일반화 성능 확인
↓
과적합 판정
Train AUC vs Test AUC Gap 비교
Decision Tree(0.3155) / Random Forest(0.1031) 심각
XGBoost(0.0638) / LightGBM(0.0840) 의심
↓

ROC Curve 시각화
6개 모델 AUC 한눈에 비교
↓
Feature Importance (XGBoost)
상위 5개 변수 선택
total_review_cnt / total_watch_minutes / recommendation_ctr 모델링 분석 흐름 총 정리 8

total_search_cnt / total_watch_cnt
↓
XGBoost 재학습 (상위 5개 변수만)
↓
하이퍼파라미터 튜닝 (RandomizedSearchCV)
50회 무작위 탐색 × 5-Fold CV = 250번 학습
과적합 억제 파라미터 집중 탐색
(max_depth / gamma / reg_alpha / reg_lambda 등)
CV Best AUC : 0.9064
↓
튜닝 후 과적합 재판정
XGBoost(tuned) → ✅ 안정적으로 개선
↓
임계값(Threshold) 조정
Recall ≥ 0.75 우선 → FN(미탐지) 최소화
↓
혼동 행렬(Confusion matrix) 조정
FN (미탐지 휴면 유저) : 78명
TP (정확히 탐지한 휴면 유저) : 264명
Recall : 0.7719
↓
KS 분석
휴면(1) vs 정상(0) 예측 확률 분포 분리도 확인
↓
IV 분석
변수별 예측력 측정
total_watch_minutes(2.23) / total_review_cnt(1.74) → ⚠️ Data Leakage 의심
total_search_cnt(0.14) → ✅ 유의미
↓
PSI 분석
Train vs Test 예측 확률 분포 안정성 확인

PSI < 0.1 → ✅ 모델 안정적타겟 변수 설정

추가 의견

→ 세그먼트별 사용자 행동에 대한 예측에 영향력이 높은 DATE 관련 컬럼이 있다면 추후 시 계열 분석 등 더 정확한 예측 분석을 할 수 있을 것 같다.