**모든 테이블**

중복 행 제거 — 모든 값이 완전히 동일한 중복 행 존재

True/False -> 0/1 — 원본 데이터 로드 시 BOOLEAN을 TEXT로 가져왔기 때문에 변환 필요

**users**

**age** : 컬럼 범주형화 (9세 이하, 10대~60대, 70세 이상, Unknown(NULL, 0이하, 100초과))

— 해석 가능성을 높이기 위해 연령대 기준의 범주형 변수로 재구성, NULL과 현실적으로 타당하지 않은 값으로 판단한 0이하 & 100초과 값은 'Unknown' 범주로 분리 (결측치 비율: 약 12%, 오류값 비율: 약 0.3%)

**gender** : NULL, 'Prefer not to say' -> 'Unknown'

— 범주형 컬럼, 성별 미제공 상태를 하나로 묶어 'Unknown' 범주로 표현 (결측치 비율: 약 8%)

**household_size** : NULL -> 최빈값

— 1~8 사이의 정수값만을 갖는 이산형 컬럼, 수치형이지만 연속적인 양적 의미보다는 가구 규모를 나타내는 범주적 성격이 강함 (결측치 비율: 약 15%)

**subscription_start_date** : 컬럼 삭제

— 구독 시작일이 계정 생성일보다 빠를 수 없음, 구독 시작일이 계정 생성일보다 빠른 경우의 비율이 높음 (오류값 비율: 약 52%)

**monthly_spend** : NULL -> 중앙값 / 이상치 -> 상한값

— 연속형 수치를 값으로 하는 컬럼, 극단값 다수 존재, 중앙값은 극단값에 대한 민감도가 낮음 (결측치 비율: 약 10%)

— 극단값의 영향력을 제한하면서도 데이터 손실을 방지

**movies**

**genre_secondary** : NULL 유지

— 보조 장르는 존재하지 않는 경우가 자연스러운 콘텐츠 속성 (결측치 비율: 약 64%)

**imdb_rating** : NULL 유지

— 평점 미집계 · 비공개 작품에서 정상적으로 결측이 발생 (결측치 비율: 약 14%)

**production_budget** : NULL 유지

— 제작비는 공개되지 않는 경우가 많아 임의 대체 시 왜곡 (결측치 비율: 약 65%)

**box_office_revenue** : NULL 유지

— OTT 전용 콘텐츠는 흥행 수익 정보가 존재 X (결측치 비율: 약 68%)

**number_of_seasons** : NULL 유지

— 시즌 개념이 적용되지 않는 콘텐츠 다수 존재 (결측치 비율: 약 72%)

**number_of_episodes** : NULL 유지

— 에피소드 수는 시리즈에만 의미가 있는 정보 (결측치 비율: 약 69%)

**duration_minutes** : 이상치 -> 300분 / 오류값(duration_minutes = 0) -> 해당 콘텐츠 타입의 평균값

— 박스플롯으로 분포 확인 시 최대값은 약 200분이고, 300분~600분에 이상치 모두 존재

— 콘텐츠 타입에 따라서 평균 duration_minutes에 편차 존재

**watch_history**

**user_rating** : NULL 유지

— 시청 후 평점을 안 남긴 상태를 의미 (결측치 비율: 약 80%)

**watch_duration_minutes** : NULL -> 중앙값 / 이상치 -> 상한값

— 연속형 수치를 값으로 하는 컬럼, 극단값 다수 존재, 중앙값은 극단값에 대한 민감도가 낮음 (결측치 비율: 약 12%)

— 극단값의 영향력을 제한하면서도 데이터 손실을 방지

**progress_percentage** : NULL -> 평균

— 연속형 수치를 값으로 하는 컬럼 (결측치 비율: 약 8%)

(콘텐츠 타입별 평균 watch_duration_minutes와 progress_percentage 값을 구해봤을 때 콘텐츠 타입 간의 편차 크지 X)

**recommendation_logs**

**algorithm_verstion** : NULL -> 'Unknown'

— 범주형 컬럼, 알고리즘 정보 미제공 상태를 'Unknown' 범주로 표현 (결측치 비율: 약 5%)

**recommendation_score** : NULL 유지

— 점수 산출 과정에서 누락된 것으로 판단, 추천 품질 평가는 하지 않으므로 NULL 유지 (결측치 비율: 약 10%)

**search_logs**

**clicked_result_position** : NULL 유지

— 검색 후 클릭이 발생하지 않은 경우를 의미 (결측치 비율: 약 51%)

**search_duration_seconds** : NULL -> 중앙값 / 이상치 -> 상한값

— 연속형 수치를 값으로 하는 컬럼, 극단값 존재, 중앙값은 극단값에 대한 민감도가 낮음 (결측치 비율: 약 5%)

— 극단값의 영향력을 제한하면서도 데이터 손실을 방지

**reviews**

**review_text** : NULL 유지

— 리뷰 텍스트가 NULL이어도 리뷰 내용에 대한 sentiment_score는 존재하므로 텍스트 미작성이 아닌 데이터 누락이라고 판단, 텍스트 분석은 하지 않으므로 NULL 유지 (결측치 비율: 약 5%)

**sentiment_score** : NULL -> 감성 범주별 평균

— 리뷰 텍스트 기반 감성 점수 계산 과정에서의 기술적 누락으로 판단, sentiment별 평균 sentiment_score으로 대체 (positive 0.8, neutral 0.501, negative 0.194) (결측치 비율: 약 8%)

**total_votes** : NULL -> 0

— NOT NULL인 경우 모두 1~16 사이의 값을 가지므로 NULL인 경우는 투표를 받지 못한 경우 (결측치 비율: 약 12%)

**helpful_votes** : NULL -> 0

— NOT NULL인 경우 모두 1~13 사이의 값을 가지므로 NULL인 경우는 투표를 받지 못한 경우 (결측치 비율: 약 16%)

(total_votes가 NULL인데 helpful_votes가 NOT NULL인 오류는 없음)